

Introduction au Machine Learning

Formation ML — Séance 1

Suite logique de la Formation Python 360°

26 septembre 2026

Au programme aujourd'hui

1. Qu'est-ce que le Machine Learning ?
2. Le vocabulaire essentiel
3. Premier contact avec des données réelles
4. Prise en main de l'environnement
5. Travail pratique guidé

Intuition — Objectif de la séance : repartir avec une intuition solide du **pourquoi** du ML, avant d'entrer dans le **comment** dès la séance 2.

Le programme complet de la formation

#	Séance	Date
1	Introduction au Machine Learning	sam. 26 sept.
2	Régression Linéaire & Descente de Gradient	mer. 30 sept.
3	Classification & Régression Logistique	sam. 3 oct.
4	Généralisation, Validation & Prétraitement	mer. 7 oct.
5	Modèles à base d'Arbres & Réduction de dimension	sam. 10 oct.
6-7	Projet guidé (en 2 temps)	mer. 14 oct. / sam. 17 oct.
8	Évaluation & restitution des projets	mer. 21 oct.

California Housing et Titanic nous accompagnent tout du long.

1. Qu'est-ce qu'une donnée ?

D'une table à un problème de ML

MedInc	HouseAge	AveRooms	...	MedHouseVal
8.3	41	6.98	...	4.53
5.6	21	6.24	...	3.59
3.8	52	5.82	...	3.15

- Chaque **ligne** = une observation (un district californien)
- Chaque **colonne** = une **feature** — sauf une, la **target**
- La target est ce qu'on veut **prédire**

L'espace des features

Chaque observation peut se voir comme un point dans un espace à autant de dimensions que de features.


- 1 feature → une droite
- 2 features → un plan
- 8 features (California Housing) → un espace qu'on ne peut plus dessiner, mais dont le principe reste identique

À retenir — On ne perd rien à raisonner en 2D pour comprendre — les mêmes idées se généralisent, juste sans schéma possible.

2. Programmation classique vs. apprentissage


Deux façons radicalement différentes de résoudre un problème

Programmation classique



On code la logique nous-même.

Machine Learning



Le modèle "trouve" la logique.

Attention — le ML n'est pas magique : il a besoin d'exemples représentatifs pour apprendre une règle qui généralise correctement.

Pourquoi maintenant ? Les limites du classique

Pour beaucoup de tâches, écrire les règles à la main est **impossible en pratique** :

- Détection de spams, reconnaissance faciale
- Traduction automatique, diagnostic médical
- Prédiction financière, recommandation de contenu

Intuition — Point commun : personne ne sait écrire "la formule" qui distingue un spam d'un email normal. On a par contre des **milliers d'exemples** des deux — c'est cette matière première que le ML exploite.

Deux définitions qui font référence

Arthur Samuel (1959) — le terme lui-même : *"Machine Learning est le domaine d'étude qui donne aux ordinateurs la capacité d'apprendre sans être explicitement programmés."*

Tom Mitchell (1997) — définition opérationnelle : un programme apprend d'une **expérience E**, pour une **tâche T** et une **mesure de performance P**, si sa performance à T, mesurée par P, s'améliore avec E.

Exemple : jouer aux échecs (T), % de victoires (P), parties d'entraînement jouées (E).

Les trois grandes familles

Type	Principe	Exemple
Supervisé	On connaît la bonne réponse pendant l'entraînement	Prix d'un logement, survie d'un passager
Non-supervisé	Pas de bonne réponse fournie, on cherche une structure	Regrouper des clients similaires
Renforcement	Un agent apprend par essai/erreur avec des récompenses	Un robot qui apprend à marcher

Non-supervisé, en détail : regroupement (clustering), réduction de dimension, estimation de densité — vu en Séance 5.

Ce module se concentre sur le supervisé (S1-S6), avec un aperçu du non-supervisé en S5.

À l'intérieur du supervisé

Régression

La target est une valeur **continue**

Exemple : prix d'un logement

→ **Séance 2**

Classification

La target est une **catégorie**

Exemple : survécu / n'a pas survécu

→ **Séance 3**

3. Le vocabulaire essentiel

Modèle, paramètres, hyperparamètres

Un **modèle** est une fonction paramétrée : on choisit sa *forme* (ex : une droite), et l'entraînement ajuste ses **paramètres** (ex : la pente) pour qu'elle colle le mieux aux données.

- **Paramètres** — ajustés automatiquement pendant l'entraînement (ex : w , b)
- **Hyperparamètres** — choisis par nous, avant l'entraînement (ex : le learning rate)

À retenir — On reverra cette distinction à chaque séance — elle est centrale pour comprendre ce qu'on contrôle et ce que le modèle apprend seul.

Train / Validation / Test

Attention — On ne peut jamais juger un modèle sur les données qu'il a déjà vues à l'entraînement.

Ensemble	Rôle
Train	Le modèle apprend dessus
Validation	On compare des modèles / réglages entre eux
Test	Évaluation finale, une seule fois, à la toute fin

Pourquoi ? → notion de **généralisation** : bien faire sur du jamais-vu, pas seulement sur ce qu'on a mémorisé.

(On creuse ce point en profondeur en Séance 4.)

4. Premier contact : California Housing

Le fil rouge du module

California Housing nous accompagne de la Séance 1 au projet final. On l'observe sous des angles différents à chaque séance.

- **8 features** : revenu médian, âge des logements, nombre de pièces, population, position géographique...
- **1 target** : **MedHouseVal**, la valeur médiane du logement
- **20 640 districts** californiens (recensement 1990)

Aujourd'hui : on observe, on ne modélise pas encore.

Ce qu'on va regarder ensemble

1. À quoi ressemblent les données brutes ?
2. Comment se distribue le prix des logements ?
3. Le revenu médian semble-t-il lié au prix ?

Exercice — Question à garder en tête : si tu devais deviner le prix d'un logement **sans** ML, comment t'y prendrais-tu ?

5. Setup & travail pratique

Environnement de travail

Outil	Usage
Google Colab	Exécution des notebooks, aucune installation
GitHub — formation-ml	Notebooks, ressources, structure du module
Google Classroom	Annonces, ressources complémentaires
WhatsApp	Questions rapides, entraide

À retenir — Premier réflexe dans Colab : **Fichier ► Enregistrer une copie dans Drive**, avant de toucher au code.

Travail pratique guidé (35 min)

Dans `notebook_pratique_introduction.ipynb` :

1. Choisir une feature (autre que `MedInc` / `MedHouseVal`)
2. Calculer ses statistiques descriptives
3. Produire une visualisation
4. Rédiger une interprétation en 2-3 phrases

Exercice — Bonus si le temps le permet : visualiser Latitude/Longitude — qu'est-ce que ça dessine ?

Débrief

Ce qu'on retient

- Le ML apprend des **règles à partir de données**, plutôt qu'on les écrive à la main
- On a des **features** et une **target**
- On distingue **paramètres** et **hyperparamètres**
- On ne juge jamais un modèle sur ce qu'il a déjà vu

Intuition — On a des features, une target — il nous manque une **fonction** qui relie les deux, et une façon de la trouver **automatiquement**.

→ **Séance 2 : régression linéaire & descente de gradient**

Merci !

Questions ?

Canal WhatsApp — questions ML